ТЕХНОСФЕРА

Современные методы и средства построения систем информационного поиска

ЛЕКЦИЯ 5: булев индекс и поиск (**часть 2**)

Москва, Mail.ru 2018

Еще раз о сжатии

1. **Simple9**
2. Бинарные данные в Python

Словарь поиска

3. Представление стоп-слов
4. Хранение словаря

Дерево запроса

5. Исполнение дерева
6. Парсинг запроса

Общий workflow

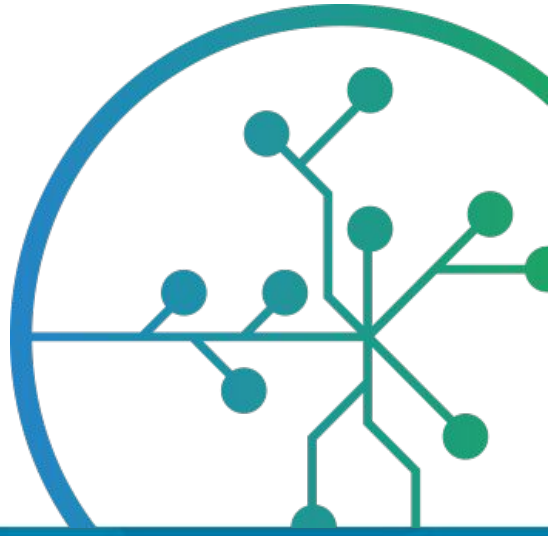

Вспомним сжатие

- VarByte – быстрый, но избыточный
- Fibonacci – компактный, но медленно
- Gamma – избыточны + нечетны по битам

Simple9

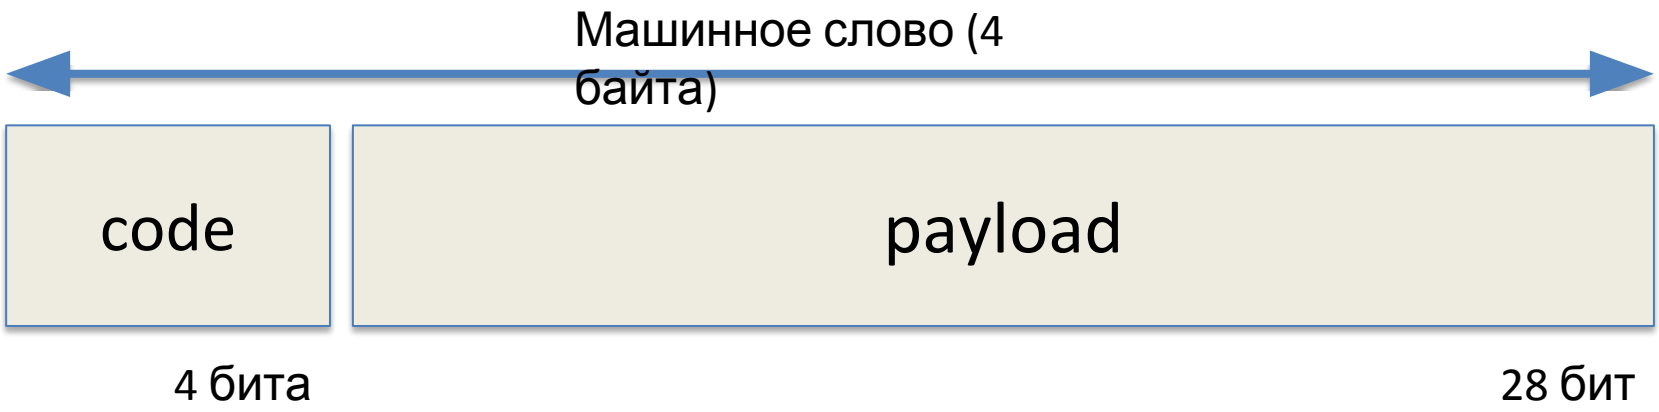

Simple9: payload

- 1 28-и битное число
- 2 14-и битных числа
- 3 9-и битных числа (и теряем 1 бит)
- 4 7-и битных числа
- 5 5-и битных чисел (и теряем 3 бита)
- 7 4-х битных чисел
- 9 3-х битных чисел (и теряем 1 бит)
- 14 2-х битных чисел
- 28 1 битных чисел

Simple9

- Плюсы:
  - Очень быстр при распаковке ($2*10^9$ чисел/сек)
  - Компактен
- Минус:
  - Избыточен для одного числа

Когда какое сжатие использовать?

– Сжатие списка документов
– Сжатие вхождений слов в документ

Еще раз о сжатии

1. Simple9
2. **Бинарные данные в Python**

Словарь поиска

3. Представление стоп-слов
4. Хранение словаря

Дерево запроса

5. Исполнение дерева
6. Парсинг запроса

Общий workflow

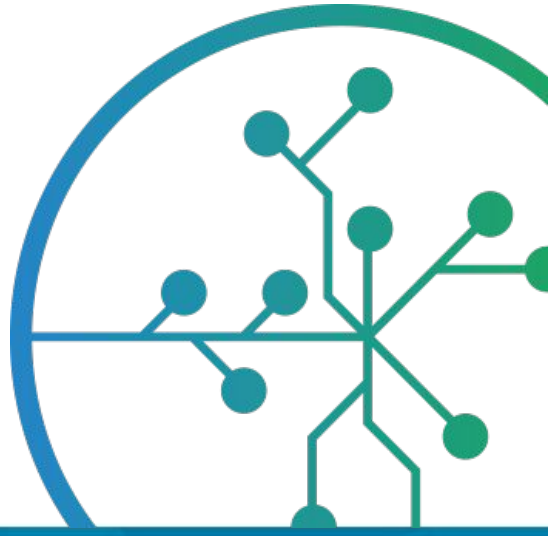

Бинарное представление данных против текста

- Если много данных, необходимо бинарно
- Меньше размер
- Существенно меньше время на операции
- Фиксированный размер/вычислимые смещения

Python и двоичные данные

import struct

- struct.pack(*fmt*, *v1*, *v2*, ...)
  - ‘h’, ‘i’, ‘q’
- struct.unpack(*fmt*, *string*)
- struct.unpack_from(*fmt*, *buffer*[, *offset=0*])

- Аналог sizeof(): struct.calcsize(*fmt*)

Python и двоичные данные

import array

- array.array(*typecode) # аналогично struct.pack*
- Наполняем с append()
- Сохраняем с tostring/tofile
- Загружаем с fromstring/fromfile

Хранение бинарных данных

- array.array(‘c’) # медленно
- cStringIO.StringIO()
- bytearray

Еще раз о сжатии

1. Simple9
2. Бинарные данные в Python

Словарь поиска

3. Представление стоп-слов
4. Хранение словаря

Дерево запроса

5. Исполнение дерева
6. Парсинг запроса

Общий workflow

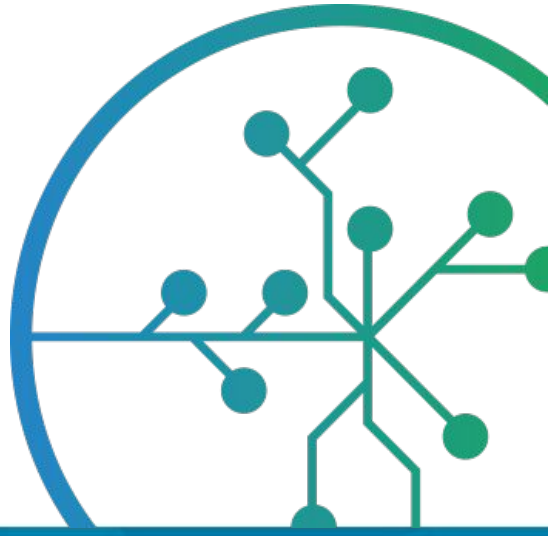

Словарь

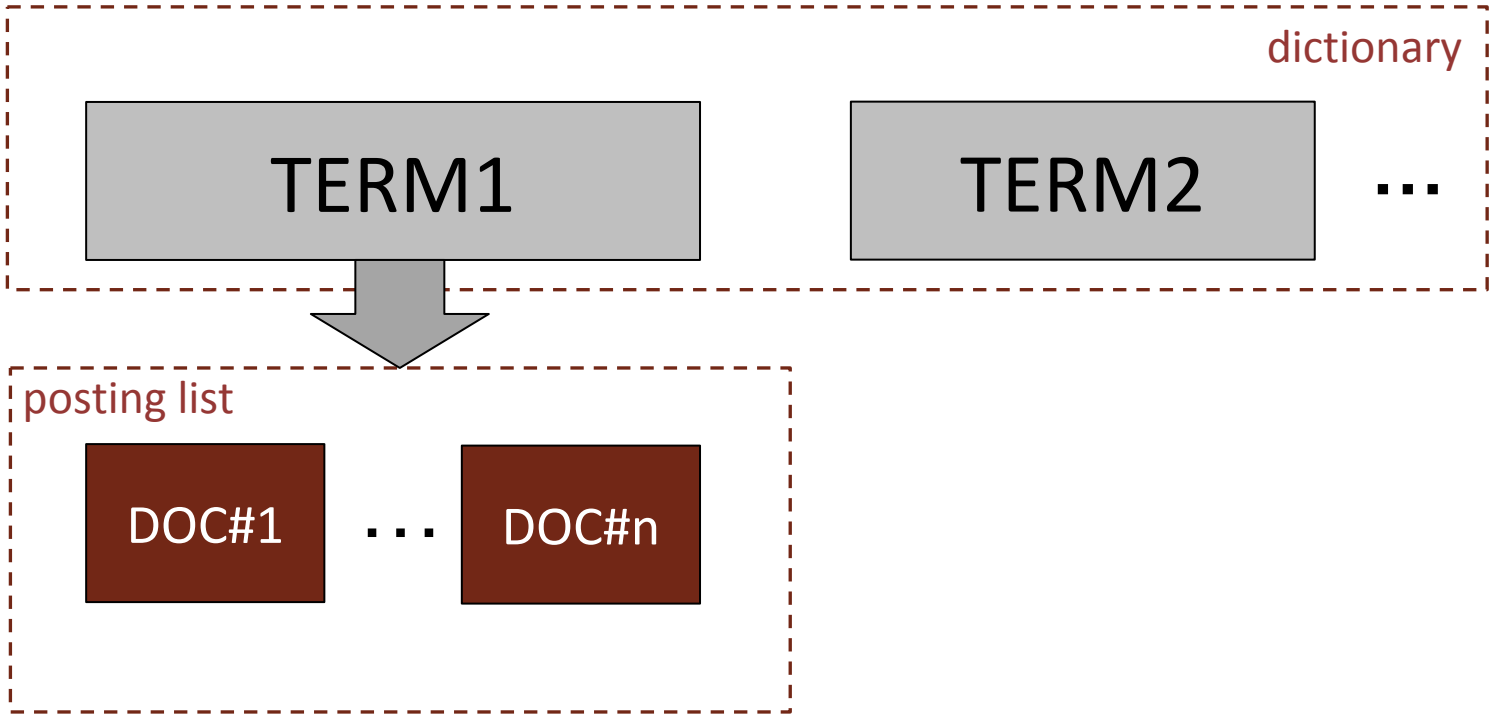

Как хранить

- Кол-во термов будет расти с ростом текста:
  - ошибочные написания
  - разные тематики: медицина, IT, …
  - подходы к хранению стоп-слов
- Средняя длинна терма = 7.5 символов
- Но достигает и 20+ символов

Как искать?

- Как искать терм в таком массиве? Т.е. какую структуру данных можно использовать?

Терм	частотность	Координаты блока
a	656 256	32
aachen	65	63216
…		
zulu	342	→

Как искать?

- Как искать терм в таком массиве? Т.е. какую структуру данных можно использовать?

Терм	частотность	Координаты блока
a	656 256	32
aachen	65	63216
…		
zulu	342	→

Основные используемые структуры данных – хэши и деревья
Выбор, в основном, зависит от назначения поиска:

- Надо искать кош* {ка, ек, ам, ке, ку, ках} – деревья
- Надо искать одно слово - хэш

Хэши

- Представление слова хэшируем в x постоянной длинны
- Боремся с коллизиями
- Или берем x=64 и хорошую хэш-функцию
- Плюсы:
  - Время поиска O(1)
- Минусы:
  - Элементы хэша никак не связаны
  - Нельзя искать строку по префиксу
- Теоретически, можно сделать морфологическую хэш-функцию

Морфологический хэш

- Rambler:

  Кошку →

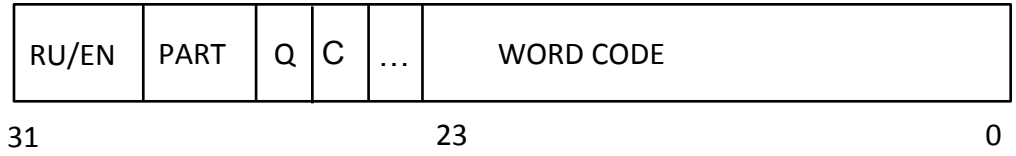

- **go.mail.ru:**

  Кошку → **“КОШКА”** → **mmhash64(…)**

Деревья

- Позволяют искать термы с общим префиксом
- Простейшее дерево – бинарное
- Поиск медленнее хэшей, O(log M), где M – размер словаря

Бинарные деревья поиска

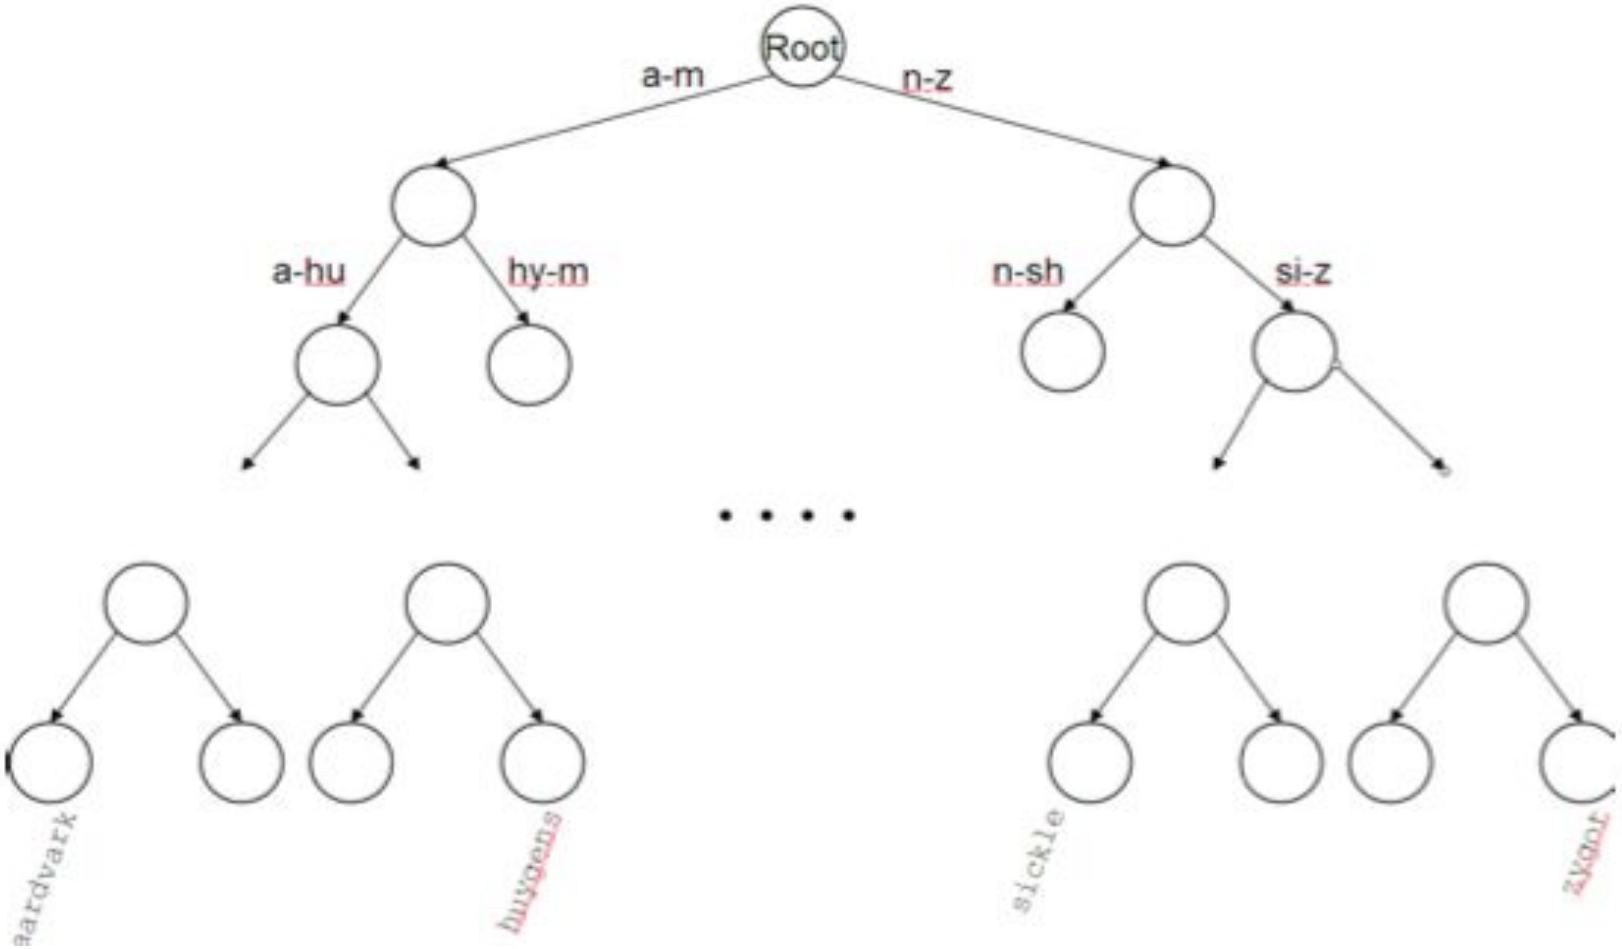

Поиск с метасимволами

- Чтобы искать кошк*
  - Используя B-дерево просто собираем все листья от «кошк»
- Искать *ошка
  - Создаем дерево записанное задом-наперед
  - Ищем аналогично первому случаю
- Результат – множество терминов подходящих под маску
- Теперь нужно найти документы содержащие эти термины

Обработка «*» внутри термина

- кош*а
  - Можно поискать в B-дереве префикс и окончание
  - И пересечь 2 множества
  - Довольно расточительно
- Можем использовать k-граммы:
  - «Кошка» → “$К” “КО” “ОШ” “ШК” “КА” “А$”
  - Строим индекс по таким биграммам
  - Преобразуем запрос “$К” AND “КО” AND “ОШ” AND “А$”
- Можем обрабатывать сложные случаи:
  - к*ш*а

- Почему большие поисковики не используют поиск с метасимволами?

- Почему большие поисковики не используют поиск с метасимволами?

- Неудобные запросы
- Очень много слов
- Как исправлять опечатки?

Еще раз о сжатии

1. Simple9
2. Бинарные данные в Python

Словарь поиска

3. **Представление стоп-слов**
4. Хранение словаря

Дерево запроса

5. Исполнение дерева
6. Парсинг запроса

Общий workflow

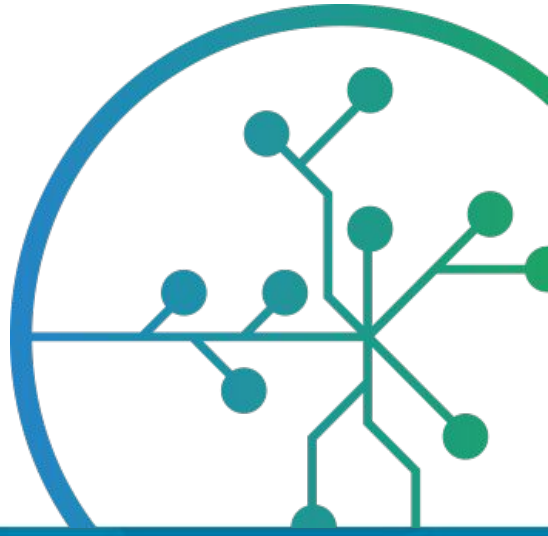

Что такое стоп-слова

- Слова с наивысшей частотой
- Как правило, не имеют смысла без контекста
- Имеют большое значение для цитат, меньшее – для других запросов

- И, ИЛИ, О, …
- Также специфические: “купить”, …

Проблемы хранения

- Присутствуют в каждом документе
  - Можем создавать инверсный индекс
    - Подходит для булевского поиска
  - Игнорировать
    - Все равно большинство запросов работают
    - Уменьшаем индекс
  - Можем учитывать контекст

Стоп-слова с контекстом

… частично из-за наследования и полиморфизма …

⇒ НАСЛЕДОВАНИЕ И ПОЛИМОРФИЗМ

Представим контекст специальными биграммами:

- Term1: НАСЛЕДОВАНИЕ → hash(..)
- Term2: НИЕ_И → hash(..)
- Term3: И_ПОЛ → hash(..)
- Term4: ПОЛИМОРФИЗМ → hash(..)

Стоп-слова с контекстом

- Раздуваем словарь т.к. комбинации слов
- Обеспечивают небольшой список вхождений
- Позволяют искать цитаты

Итог по словарю

- Словарь – адресует блоки индекса
- Обычно строится используя хэши
- Стоп-слова: важны особенно при цитатном поиске
- Размер словаря имеет значение
- Как правило, хранится в памяти (Random access)

Еще раз о сжатии

1. Simple9
2. Бинарные данные в Python

Словарь поиска

3. Представление стоп-слов
4. **Хранение словаря**

Дерево запроса

5. Исполнение дерева
6. Парсинг запроса

Общий workflow

Python: словари

- Используем обычный dict()
- Сериализация?
- **import pickle**
  - pickle.dump(*obj*, *file*[, *protocol*])
  - load

Не компактен и требует полной загрузки

Сериализация сложных данных

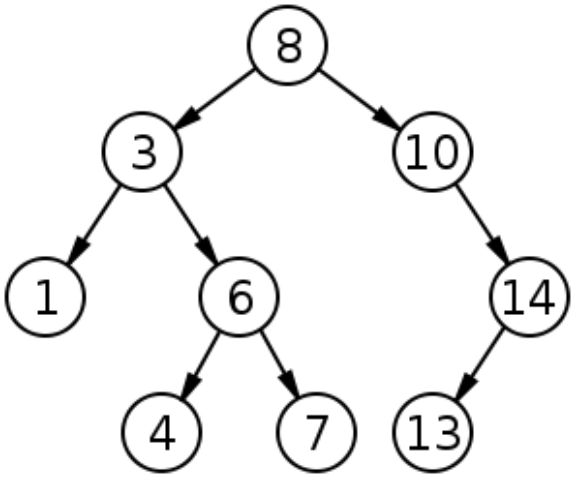

8	3	10	1	6	-1	14	-1	-1	4	7	-1	-1	13	-1

Размер: sizeof(item)*$2^{depth-1}$

Представление хэш-таблицы

- Считаем, что ключ фиксированного размера
- Хранимые данные - тоже
- Делим данные на корзинки % N
  - Выбираем N чтобы сгруппировать данные в ~4K
  - Сортируем по ключу

сериализация хэш-таблицы

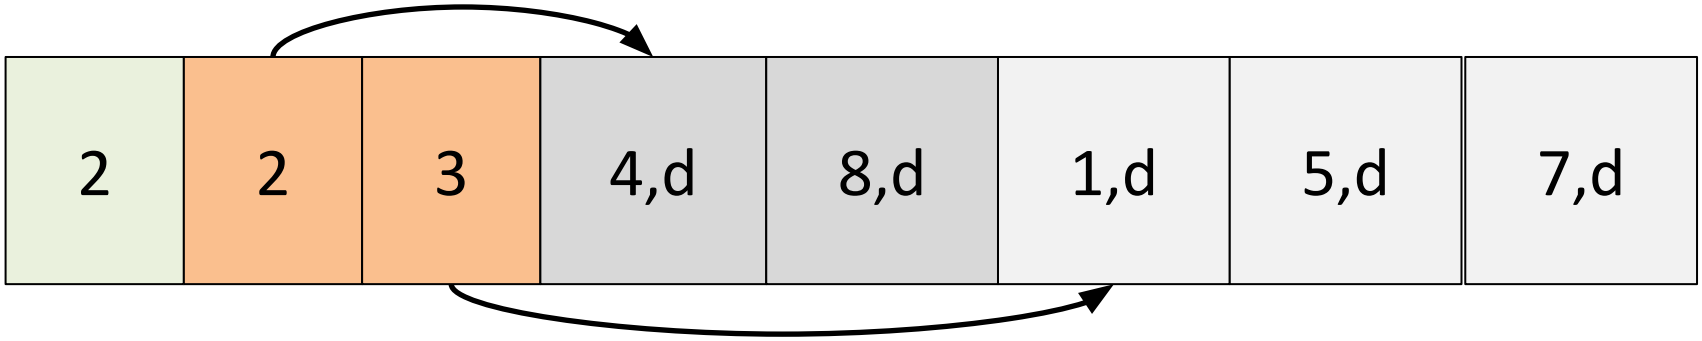

- 3 входных параметра загрузки:
  - **Кол-во корзин (N)**
  - Размерность ключа
  - Размерность данных

сериализация хэш-таблицы

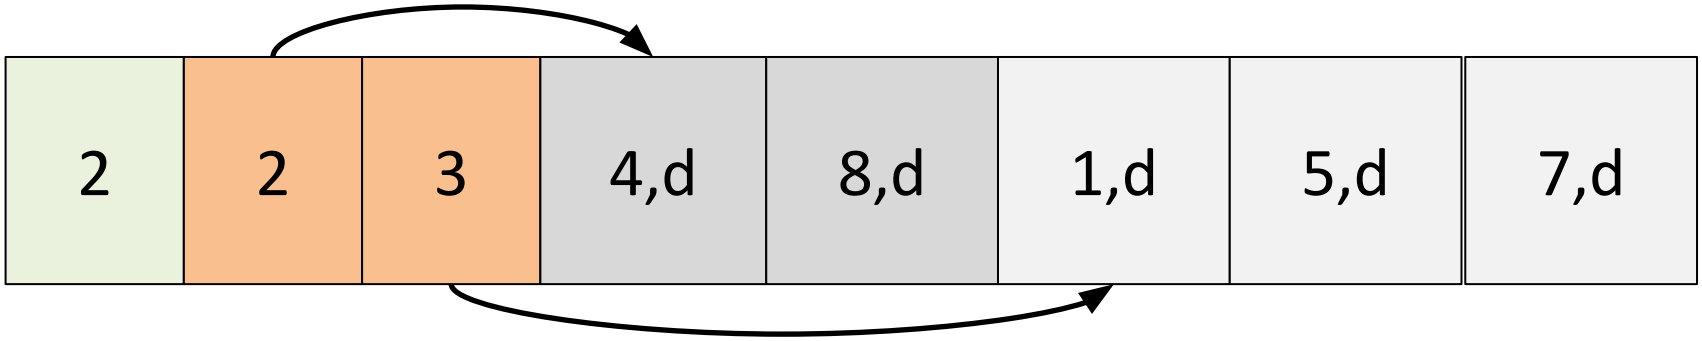

- Поиск:
  - Корзина=hash(word) % N
  - Смещение корзины известно
  - Внутри корзины – бинарным поиском по ключу
  - Возвращаем [d]

Еще раз о сжатии

1. Simple9
2. Бинарные данные в Python

Словарь поиска

3. Представление стоп-слов
4. Хранение словаря

Дерево запроса

5. Исполнение дерева
6. Парсинг запроса

Общий workflow

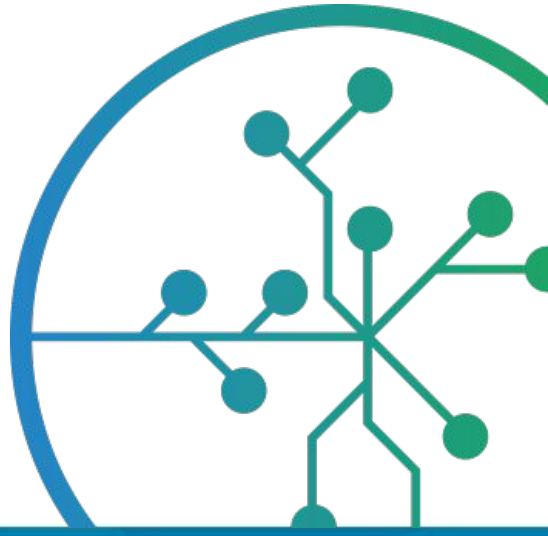

Представление запроса

- Простой случай: docker ubuntu
- Эквивалентно docker & ubuntu

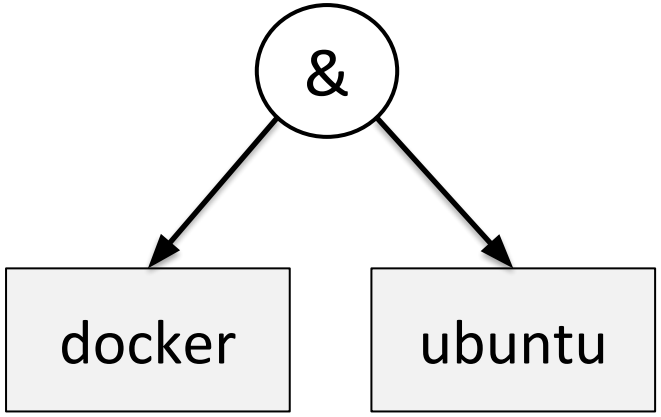

Представление запроса

- Расширим: docker & запуск & ubuntu

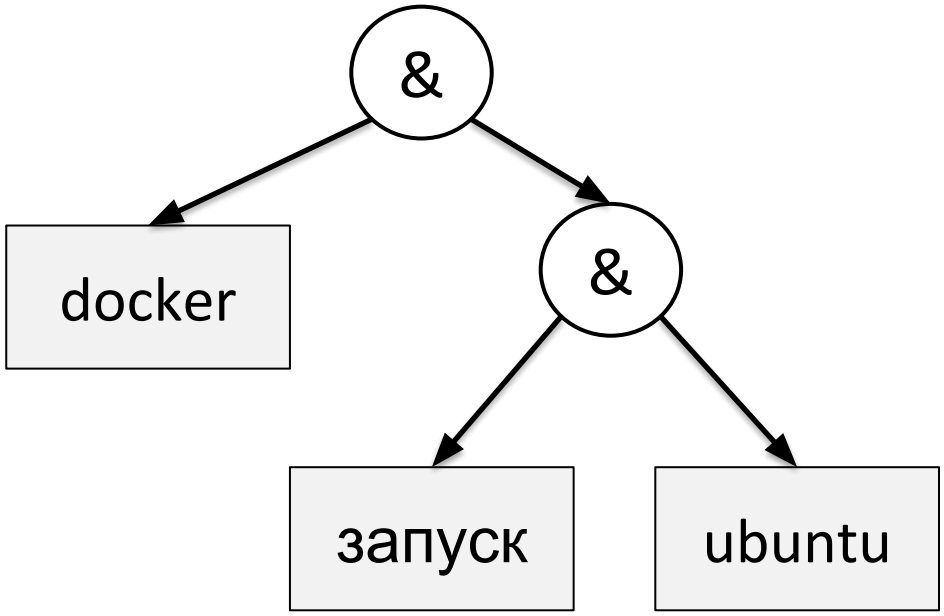

Представление запроса

- Расширим: docker & запуск & (ubuntu | убунту)

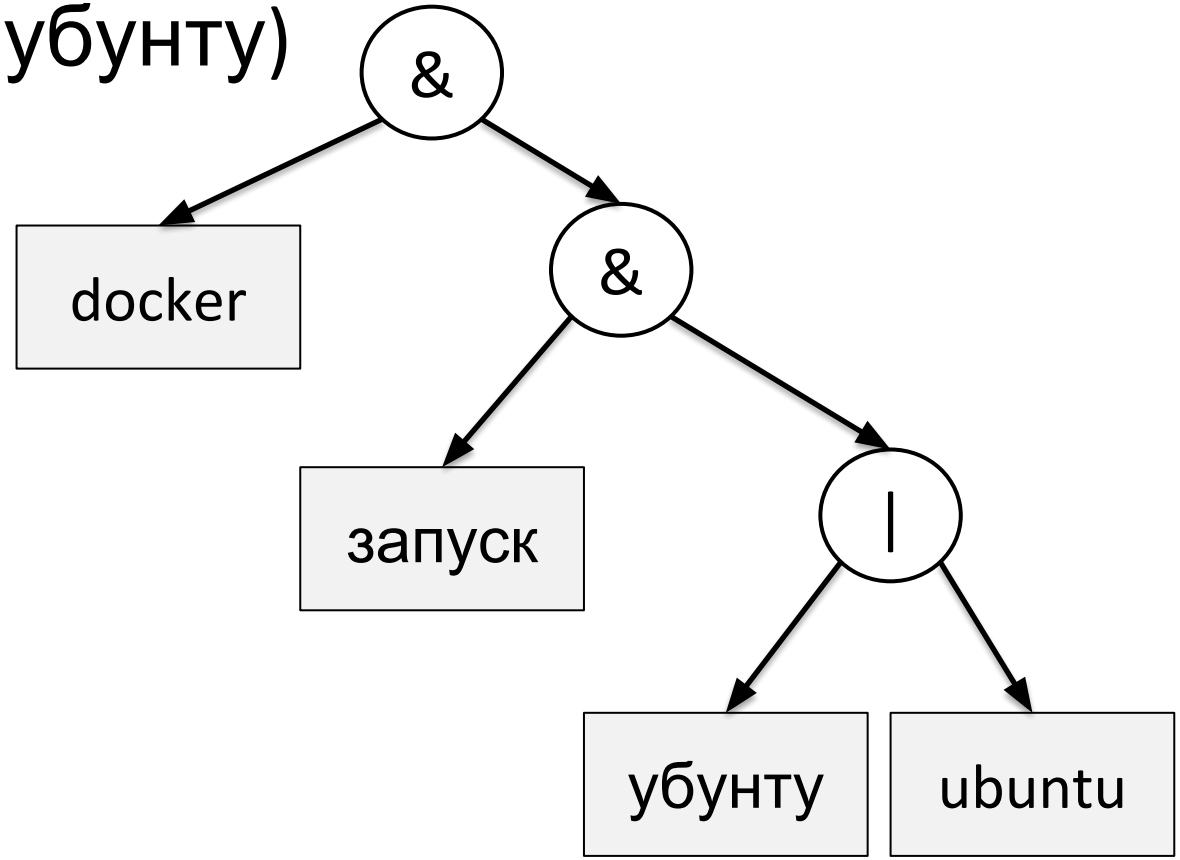

Представление запроса

- Полный: !docker & запуск & (ubuntu | убунту)

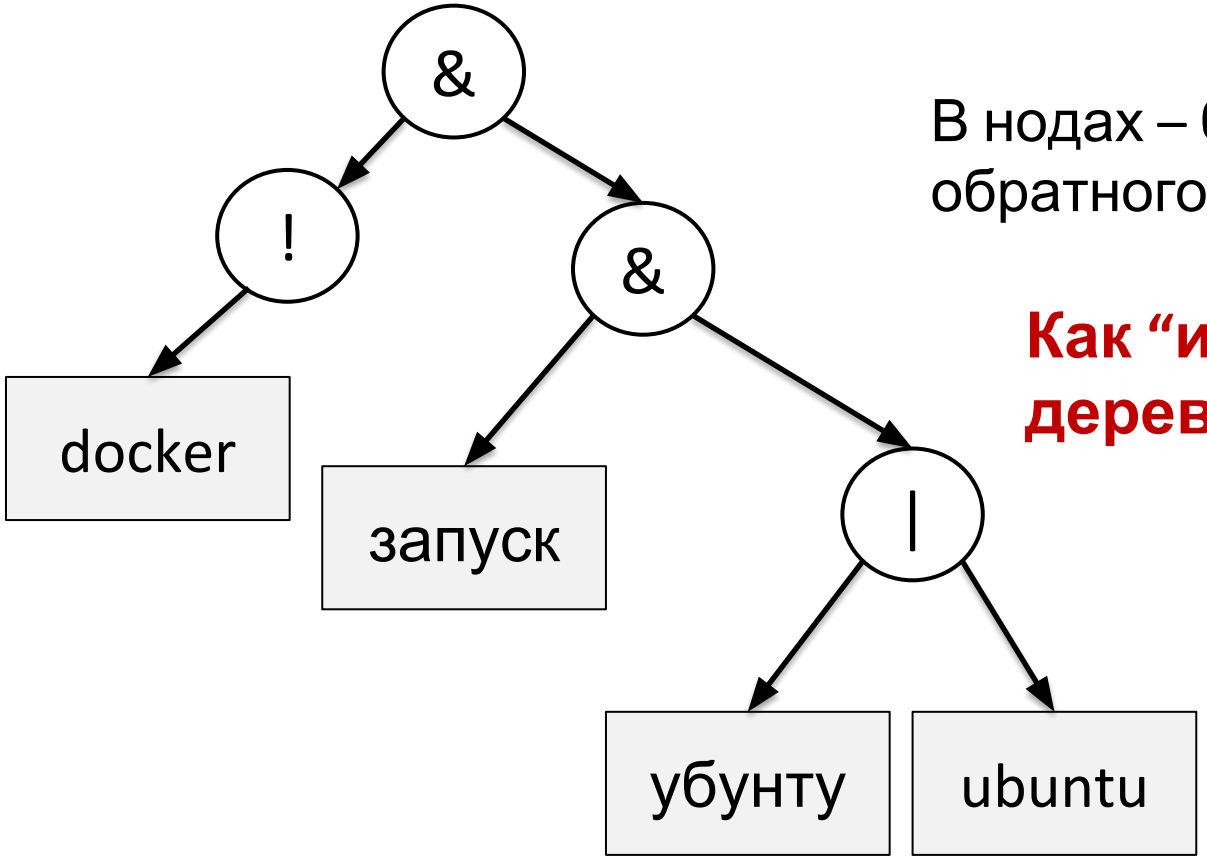

В нодах – блоки обратного индекса

Как “исполнять” такое дерево?

Еще раз о сжатии

1. Simple9
2. Бинарные данные в Python

Словарь поиска

3. Представление стоп-слов
4. Хранение словаря

Дерево запроса

5. **Исполнение дерева**
6. Парсинг запроса

Общий workflow

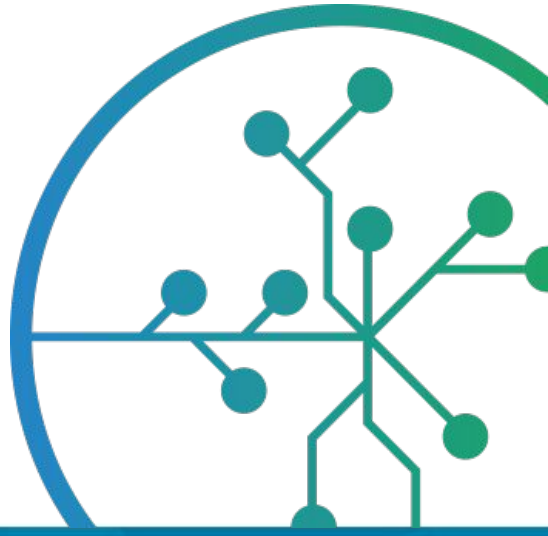

Исполнение дерева: “в лоб”

- Все термы – set-ы
- Делаем соответствующую операцию рекурсивно:
  - ! ”docker” (A)
  - “ubuntu” | убунту” (B)
  - & “запуск” (B)
  - & A
- Представим что у нас 10^7 документов
- Отрицание -> |M|

Исполнение дерева: пошагово

- Считаем что:
  - каждый узел представим потоком
    - evaluate()
    - goto(docid)
  - doc монотонно возрастает
  - 2 специальных значения: AlphaID, OmegaID

Исполнение дерева: алгоритм

- Алгоритм:
  - Разберем дерево, и свяжем каждый узел классом операций (get_current, goto)
  - Начнем с last_doc_id = AlphaID (=-1)
  - На каждом шаге рекурсивно:
    - Перемещаемся на last_doc_id+1
    - Вызываем evaluate()

Специфика термов

- Evaluate = current doc id
- Goto(docid) =
  - Пропуск всех id < docid
  - Опционально используя jump tables

Специфика дизъюнкции

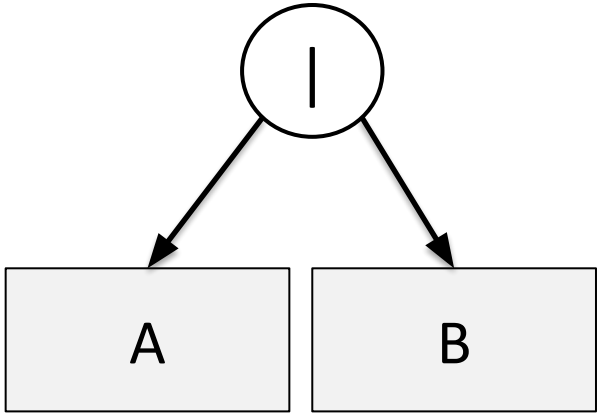

- goto(docid) =
  - A.goto(docid)
  - B.goto(docid)
- evaluate() =
  - a = A.evaluate(), b = B.evaluate()
  - (a == OmegaID) => b, (b == OmegaID) => a
  - => min(a, b)

Дополнительно для ДЗ

- Конъюнкция
- Отрицание
- Отсутствующие термы (какой случай?)

Еще раз о сжатии

1. Simple9
2. Бинарные данные в Python

Словарь поиска

3. Представление стоп-слов
4. Хранение словаря

Дерево запроса

5. Исполнение дерева
6. **Парсинг запроса**

Общий workflow

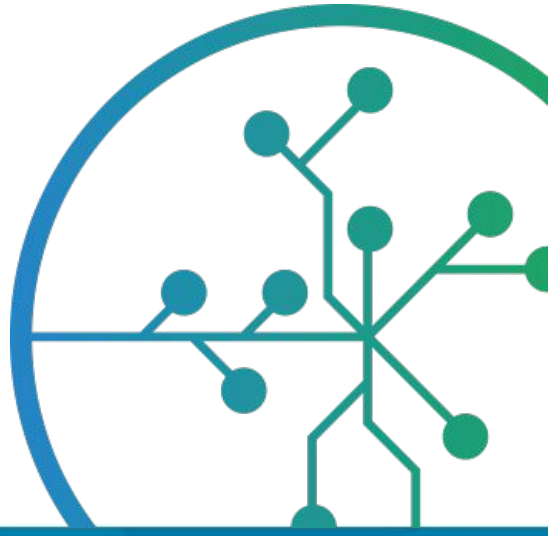

Разбор запроса

- ОК, знаем как исполнять дерево
- Необходимо сформировать из запроса
- !docker & запуск & (ubuntu | убунту)

Разбор запроса

- !docker & запуск & (ubuntu | убунту)
- Подход:
  - Токенизизация
  - Формирование дерева

Разбор запроса: токенизация

- Все токены: r'\w+|[\(\)&\|!]’
- Разбиваем на 3 класса:
  - Скобки
  - Операторы
  - Термы

Разбор запроса: дерево

- Алгоритм:
  - Находим самый низкоприоритетный оператор
    - Наиболее внешний, наиболее правый
    - Запомним как token
  - Если не нашли, значит результат = терм | None
  - Иначе:
    - token.left = рекурсивно слева
    - token.right = рекурсивно справа
    - Результат = является token

! docker & запуск & (ubuntu | убунту)

!docker & запуск

ubuntu | убунту

! docker & запуск & (ubuntu | убунту)

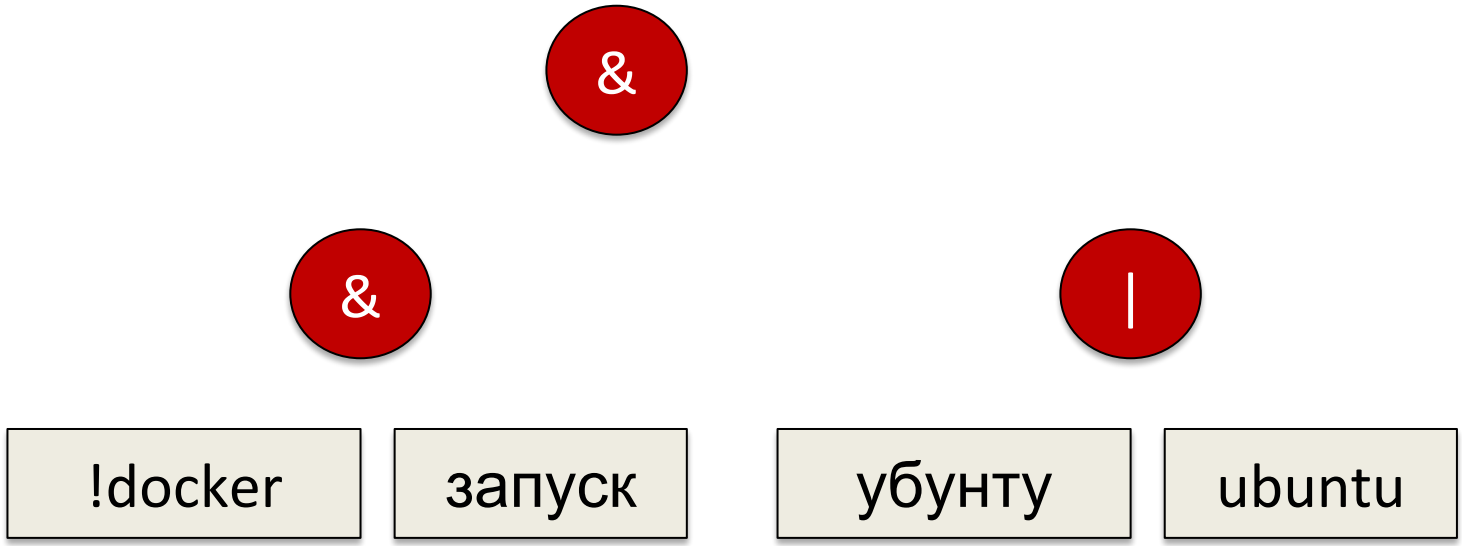

! docker & запуск & (ubuntu | убунту)

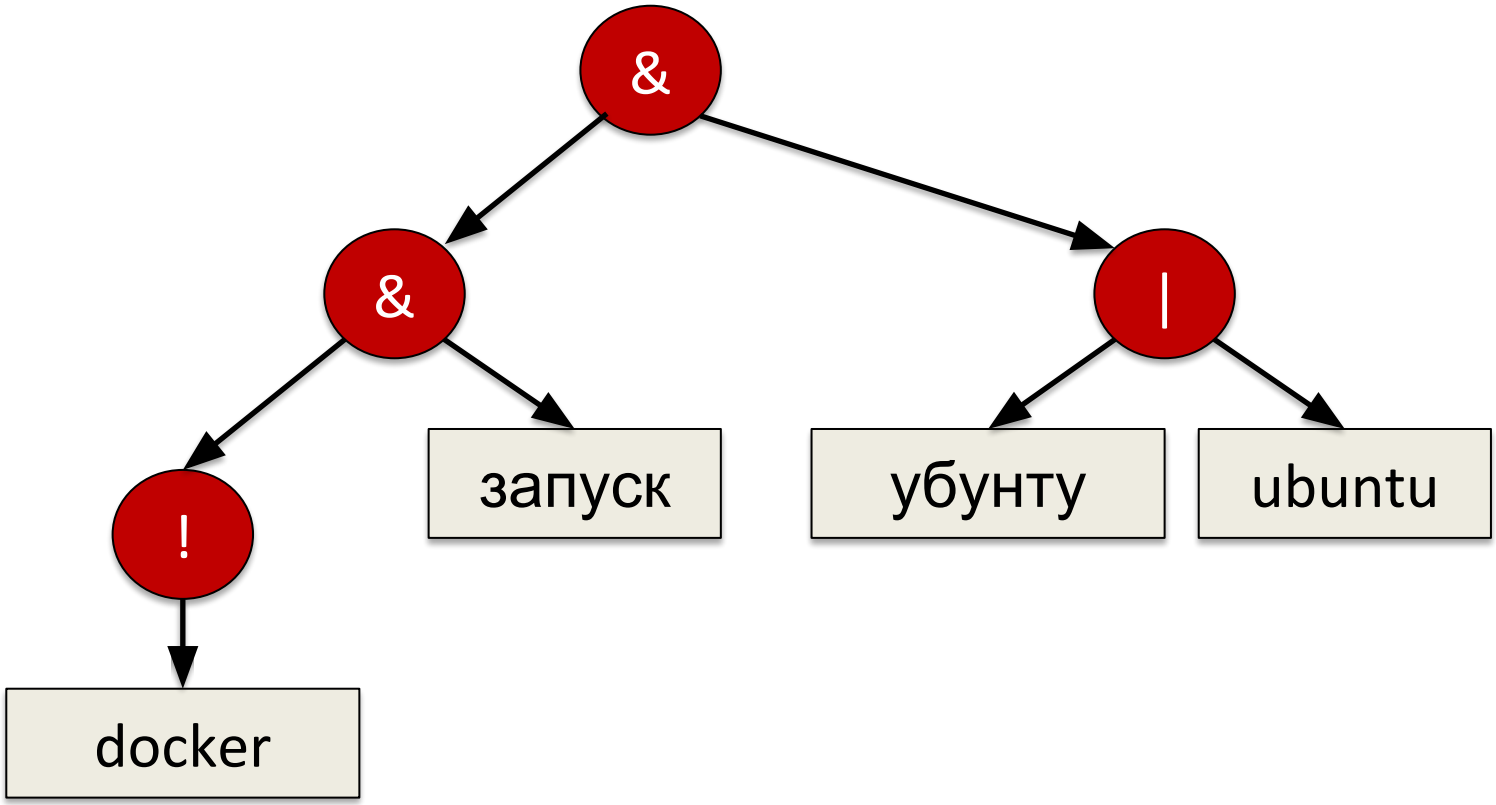

Еще раз о сжатии

1. Simple9
2. Бинарные данные в Python

Словарь поиска

3. Представление стоп-слов
4. Хранение словаря

Дерево запроса

5. Исполнение дерева
6. Парсинг запроса

Общий workflow

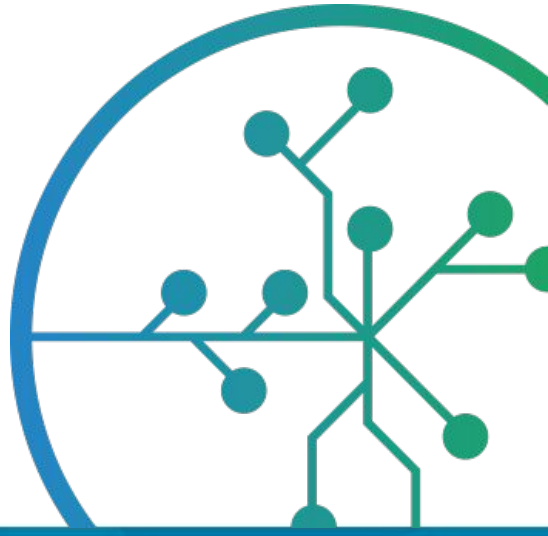

Общий workflow индексации

- Индексация входных документов [index.sh]
- Оптимизация индекс
- Построение словаря [make_dict.sh]
- Поиск [search.sh]

Workflow: индексация

- Наиболее затратна по времени
- А также по RAM
  - Для больших коллекций нельзя держать все

Поэтому:

- Сбрасываем порциями на диск
- Делаем ссылки на блоки (!= словарь)
- Сбрасываем соответствие docid -> url

Workflow: оптимизация

- Искать среди N блоков невыгодно:
  - Разрозненные обращения к диску
  - Больше N -> больше словарь
  - -//- -> хуже сжатие

Поэтому:

- Склеиваем блоки: один терм → один блок
- Строим бинарный словарь

Workflow: поиск

- Загружаем словарь
- Для каждого запроса:
  - Разбираем дерево запроса
  - Ставим в соответствие блоки
  - Пошагово получаем docid
    - Конвертируем docid в URL

Еще раз о сжатии

1. Simple9
2. Бинарные данные в Python

Словарь поиска

3. Представление стоп-слов
4. Хранение словаря

Дерево запроса

5. Исполнение дерева
6. Парсинг запроса

Общий workflow

Семинар

https://cloud.mail.ru/public/5KT9/NEHJiWRD2

https://cloud.mail.ru/public/5ueR/6jXJxtugs

Have a nice homework!